[데이터 수집 및 저장]

수집 데이터 보고서

SK Networks Family AI Camp 18 기 : HisToK 팀

산출물 단계	데이터 수집 및 저장
평가 산출물	수집 데이터 보고서
제출 일자	2025. 12. 05
깃허브 경로	SKNETWORKS-FAMILY-AICAMP/SKN18-FINAL-3TEAM
작성 팀원	이상효,박세영,김영우,양진아,안시현,장이건

1. encykorea.csv

데이터명	한국민족문화대백과사전 데이터
수집 대상	① API 기반 수집 대상 ● API 제공 항목(기본 메타데이터) ● API 응답 기반 백과사전 항목 정보 ② 크롤링 기반 수집 대상 ● APIe서 제공되지 않은 상세 본문 정보 ● 누락된 속성 보완을 위한 웹 페이지 HTML 데이터
수집 목적	RAG(VectorDB 와 GraphDB)
사용 예정 기능	조선시대사 질의응답 및 역사 동영상 제작
수집 일자	2025. 11. 26 ~ 2025. 11. 28
출처/저작권	한국민족문화대백과사전

1.1. 수집 방법 및 자동화 절차

- 수집 방식
  - API 호출
    - API 문서 기준으로는 여러 속성(컬럼)이 제공되는 것으로 명시되어 있었으나, 실제 API 응답에서는 일부 항목들이 누락되어 있었다.
  - 웹 크롤링
    - 이로 인해 분석에 필요한 데이터가 충분히 확보되지 않았으며, 이를 보완하기 위해 웹 크롤링 기반의 추가 데이터 수집 과정을 병행하였다.
- 수집 도구
  - Python
  - Playwright 라이브러리
- 수집 주기
  - 월 1 회

1.2. 데이터 설명 및 구성

- 전체 수집 데이터 건수 : 10,344 행
- 사용할 데이터 건수 : 동일
- 저장 포맷 : CSV

- API 호출 시 반환 데이터

필드명	데이터 타입	설명	예시
url	object	항목 분야별 목록 URL	https://devin.aks.ac.kr:8080/v1/Article/{항목 ID}
의의	object	본문 의의	누락
배경	object	본문 배경	누락
contentsType	object	항목 유형	누락
era	object	시대	누락
definition	object	항목 정의(제목)	누락
summary	object	요약(300 자 내외)	누락
body	object	본문	1397 년(태조 6) 10 월 왕세자 방석(芳碩)의 혼례를 위해 가례도감을 설치한 것이 효시이다. 국혼의 의론이 확정되면 설치되었고 모든 행사가 끝난 뒤에 해체되었다. 여기에는 도제조(都提調, 정 1 품) 1 인, 제조(提調, 정 2 품) 3 인, 도청(都廳, 정 3~5 품) 2 인, 낭청(郎廳, 5~6 품) 6 인, 감조관(監造官, 9 품) 6 인, 그리고 정사(正使, 정 1 품) 1 인, 부사(副使, 정 2 품) 1 인,...

필드명	데이터 타입	설명	예시
reference	object	참고문헌	『태조실록』『소현세자가례도감의궤』 『장렬왕후가례도감의궤』 『현종명성왕후가례도감의궤』 『정조효의왕후가례도감의궤』 『고종명성황후가례도감의궤』 『증보문헌비고』『조선조의 의궤』(박병선, 한국정신문화연구원, 1985) 더보기

- 크롤링 데이터

필드명	데이터 타입	설명	예시
url	object	항목 분야별 목록 URL	https://encykorea.aks.ac.kr/Article/항목 ID}
page	object	항목 분야별 목록 페이지 번호	1
card_index	object	항목 유형	0
category	object	시대	인물, 지명, 개념, 단체, 작품, 문헌, 사건, 물품, 제도, 유적, 의례/행사, 정책, 의복
title	object	게시글 제목	사화(士禍)
summary	object	요약(300 자 내외)	조선 전기 조신 및 선비들이 정치적 반대파에게 몰려 참혹한 화를 입은 정치적 사건.
contents	object	본문	네 차례의 사화는 조선이 건국된 뒤 한 세기 만에 일어난 주요한 정치적 충돌이자 숙청이었다. 정치적 충돌과 숙청은 중앙 정치에서 늘 일어나는 사건이지만 '사화(士禍)'라는 공통된 이름으로 여러 차례의 사건이 묶인 것은 조선이 개창된 뒤 처음 있는 일이었다. 사화...

1.3. 데이터 품질 및 정합성 관리 방안

- 데이터 소스 통합 방식
  - API 데이터에서 누락이 다수 확인됨에 따라, 부족한 항목을 크롤링 데이터로 보완하여 통합 데이터셋을 구축하였다. 데이터 품질 향상을 위한 검증 과정을 추가로 수행하였다.
- 중복 제거 기준
  - API 데이터와 크롤링 데이터에 대해, ["category", "title", "summary"] 3 개 컬럼을 조합한 고유값을 기준으로 중복 레코드를 제거하였다.
- 정합성 검증 방법
  - 데이터의 정합성을 확인
    - 필수 필드(title, summary, category, contents)의 존재 여부를 검증하였으며, 각 컬럼의 데이터 타입이 스키마에 적합한지 추가로 점검하였다.
- 표준화 전략
  - 스키마 일관성 확보
    - 데이터 구조의 일관성을 확보하기 위해 API 데이터와 크롤링 데이터의 컬럼명을 통일하였으며, 동일 의미를 가진 컬럼은 동일한 스키마로 조정하였다.

2. finetuning_dataset.csv

데이터명	외국인/아동
수집 대상	LLM 기반 자동 추출 및 생성 데이터 (2 차 가공 데이터)
수집 목적	LLM 파인튜닝
사용 예정 기능	단어 설명 및 대체 기능
수집 일자	2025. 12. 04 ~
출처/저작권	한국민족문화대백과사전

2.1. 수집 방법 및 자동화 절차

- 수집 방식
  - LLM 을 활용하여 contents 텍스트에서 주요 단어를 자동으로 추출하였다.
  - 추출된 단어에 대해 LLM 기반 의미(정의)를 생성하여 신규 컬럼으로 추가하였다.
- 수집 도구
  - 대규모 언어모델(LLM) 기반 텍스트 처리 도구
  - LLM 기반 키워드 추출·정의 생성 모듈
- 수집 주기
  - 월 1 회

2.2. 데이터 설명 및 구성

- 전체 수집 데이터 건수 : 약 120,000 행
- 사용할 데이터 건수 : 동일
- 저장 포맷 : CSV

필드명	데이터 타입	설명	예시
source_id	int64	추출된 단어의 원본 행	0
keyword	object	추출된 단어	복훈
prompt	object	학습을 위한 질문 형태	"'복훈'의 의미를 설명해줘."
description	object	단어의 설명	"잃은 공훈을 다시 인정해 주는 것이다."

2.3. 데이터 품질 및 정합성 관리 방안

- 정합성 검증 방법
  - ○ 필수 필드 존재 여부 확인
    - keyword, description 2개 필드는 필수 값으로 지정하였다.
    - 해당 필드가 누락된 레코드는 제거하거나 재생성 대상으로 분류하였다.
  - ○ 데이터 타입 및 형식 검증
    - source_id는 정수형(int64), keyword·prompt·description은 문자열(object) 형태인지 확인하였다.
    - description 필드는 서술형 문장("~이다.") 형태로 끝나는지 패턴 검증을 수행하였다.
    - prompt는 "~의 의미를 설명해줘."와 같은 질문 형태인지 확인하였다.
  - ○ 중복 데이터 제거
    - [keyword, description] 두 필드를 조합한 고유값을 기준으로 중복 레코드값을 제거하였다.
  - ○ 문장 품질 검증(LLM 생성 데이터 품질 확인)
    - description이 비문이거나 설명이 누락된 경우 LLM 재생성 로직을 적용하여 품질을 보완하였다.
    - 지나치게 짧거나 일반적 의미만 제시된 경우 품질 점수 기반 필터링을 수행하였다.

- 표준화 전략
  - 문체 및 형식 통일
    - 모든 description을 "~이다."로 끝나는 백과사전식 서술형으로 표준화하였다.
    - prompt는 동일한 패턴(예: "'{keyword}'의 의미를 설명해줘.")으로 자동 생성되도록 규칙화하였다.
  - 단어 정규화(전처리 표준화)
    - keyword에서 괄호 속 한자, 특수기호, 공백 등을 일관된 방식으로 정제하였다.
  - 레이블 스키마 일관성 확보
    - source_id, keyword, prompt, description 필드명을 전체 파이프라인에서 동일하게 사용하도록 정의하였다.

- 데이터 생성 과정 품질 관리(Large Language Model 기반 파생 데이터 특화)
  - LLM 출력 검증 절차 적용
    - LLM이 생성한 description이 사실적·문법적으로 타당한지 자동 검증 루틴을 적용하였다.
    - 의미가 중복되거나 문장이 불완전할 경우 재생성 또는 보정 규칙을 적용하였다.
  - 재현성(Reproducibility) 확보
    - 동일 keyword 입력 시 동일 prompt → answer가 생성되도록
      모델 버전, temperature, max_tokens 등 주요 파라미터를 고정하였다.
  - 오류 데이터 수동 점검(Sample-based QA)
    - 전체 데이터 중 표본을 추출하여 수작업 점검을 수행하고,
      불일치 패턴은 규칙 기반 정제 로직에 반영하였다.

3. education_tone_dataset.csv

데이터명	한국어 학습자용 문장 교정 데이터셋
수집 대상	YouTube 영상의 자동 생성 자막(auto-caption) 및 제공 자막
수집 목적	외국인 및 아동 등 학습자를 위해 문법적으로 올바르고, 맥락상 자연스러운 문장을 생성하기 위한 학습 데이터 구축
사용 예정 기능	자연스러운 영어/한국어 문장 생성 어휘/문법이 어렵지 않은 영어/한국어 문장 생성
수집 일자	2025. 11. 24 ~ 2025. 11. 25
출처/저작권	깨비키즈, 지니스쿨역사, Mr History

3.1. 수집 방법 및 자동화 절차

- 수집 방식
  - YouTube 자막 기반 수집
    - youtube-transcript-api를 활용하여 자동 생성 자막(auto-caption) 및 제공 자막을 수집하였다.
    - 자막이 제공되지 않는 영상에 대해서는 pytube 기반 다운로드 후 텍스트 추출을 수행하였다.
  - LLM 기반 문장 교정 자동화
    - 수집된 자막 문장에 대해 LLM을 활용하여 문법·오탈자·비문 여부를 검증하고, 필요 시 의미를 유지한 자연스러운 문장으로 자동 교정하였다.
- 수집 도구
  - youtube-transcript-api — YouTube 자막 텍스트 추출
  - pytube — 자막 미지원 영상 다운로드 및 보조 처리
  - LLM API (OpenAI 등) — 문장 교정 및 맥락 검증 자동화
  - Lilys AI
- 수집 주기
  - 일회성 (차기 개정 시 수동 업데이트 예정)

3.2. 데이터 설명 및 구성

- 전체 수집 데이터 건수 : 한국어 문장 838 행 + 영어 문장 1002 행
- 사용할 데이터 건수 : 동일
- 저장 포맷 : CSV

필드명	데이터 타입	설명	예시
label	object	언어 구분	korean_education_tone, english_education_tone
content	object	학습시키고자 하는 문장	"세종대왕은 학문을 좋아하고 여러 방면에 걸쳐 뛰어난 재능을 가졌을 뿐 아니라, 옳다고 생각하는 일은 무슨 일이 있어도 주저하지 않는 임금이셨습니다. 또한 항상 국민을 위한 정치를 행하는 성군이셨답니다. 태종의 셋째 아들로 태어났고, 충녕대군이라 불리웠죠. 원래는 큰 형 양녕대군이 왕위를 이어받을 차례였어요."

3.3. 데이터 품질 및 정합성 관리 방안

- 정합성 검증 방법
  - ○ 필수 필드 검증
    - ■ 문장 내 결측치, 공백 문자열, 특수기호, HTML태그 등의 데이터는 제거하였다.
  - ○ 문장 품질 검증
    - ■ 교정 문장이 원본 의미를 크게 훼손하지 않았는지 semantic similarity 평가적용.
    - ■ 불일치율이 높은 문장은 재교정 대상으로 분류하였다.
  - ○ 맥락 정합성 검증
    - ■ 앞·뒤 문장 간 논리적 연결 여부를 점검하였다.
  - ○ 중복·불필요 문장 제거
    - ■ auto-caption의 특성상 반복되는 문장을 제거하였다.

- 표준화 전략
  - 문장 형식 표준화
    - 마침표와 구두점 통일
    - 괄호/기호 표기 규칙 일관화
    - 줄바꿈·공백 규칙 정립
  - 텍스트 정제 기준 통일
    - 시그널 단어(음성 안내, 잡음 표시 등) 제거 규칙 통일
    - 자연어 문장만 남도록 비언어 태그 제거